Relatório Final - Características de repositórios populares

INTRODUÇÃO E HIPÓTESES INICIAIS:

Os repositórios open-source mais populares no GitHub possuem características distintas que podem indicar padrões de desenvolvimento, manutenção e engajamento da comunidade. Neste estudo, buscamos analisar 1.000 dos repositórios mais bem avaliados na plataforma, investigando métricas como idade do repositório, contribuição externa, frequência de lançamentos, tempo de atualização, linguagem utilizada e taxa de fechamento de issues.

O objetivo deste estudo é analisar as características de qualidade dos repositórios desenvolvidos em Java na plataforma GitHub, utilizando métricas específicas de produto para entender como as variáveis de processo (como popularidade, maturidade, atividade e tamanho) influenciam na qualidade do código. A pesquisa será focada em 1.000 repositórios Java, coletando dados sobre métricas de popularidade, tamanho, atividade e maturidade, além das métricas de qualidade do produto como CBO, DIT e LCOM, que são calculadas através da ferramenta CK.

Com base na intuição sobre projetos open-source populares, formulamos as seguintes hipóteses:

- **Hipótese sobre a relação entre popularidade e qualidade**: Repositórios mais populares (com mais estrelas) tendem a apresentar melhores características de qualidade, como menores valores de CBO e LCOM, devido a uma maior atenção e revisão por parte da comunidade.

- **Hipótese sobre a relação entre maturidade e qualidade**: Repositórios mais antigos têm maior maturidade e, consequentemente, características de qualidade superiores, já que um repositório com mais tempo de vida tende a ser mais refinado e otimizado.

- **Hipótese sobre a relação entre atividade e qualidade**: Repositórios mais ativos, com mais releases, demonstram melhor qualidade de código, pois isso pode indicar um processo contínuo de melhorias e correções.

- **Hipótese sobre a relação entre tamanho e qualidade**: Repositórios maiores, em termos de linhas de código, podem ter uma qualidade inferior, devido à maior complexidade que pode resultar em maior acoplamento e falta de coesão nos métodos.

METODOLOGIA

Coleta de Dados: Utilizou-se a API GraphQL do GitHub para obter informações sobre os 1.000 repositórios mais populares. A consulta incluiu dados como data de criação, pull requests aceitas, releases, última atualização, linguagem principal e issues fechadas.

Armazenamento: Os dados foram extraídos e salvos em arquivos `.csv` para facilitar a análise.

Processamento: Foi realizada uma análise estatística, utilizando valores medianos para evitar distorções por outliers. Para as métricas de qualidade, foi utilizada a ferramenta CK para gerar dados sobre características como CBO, DIT e LCOM, que foram processados e armazenados.

Análise Comparativa: Investigou-se a relação entre a popularidade da linguagem e as métricas de contribuição, releases e frequência de atualizações, além da comparação das métricas de qualidade geradas pelo CK com as características do processo de desenvolvimento dos repositórios.

Automação e Relatórios: Todo o processo de coleta, processamento e análise foi automatizado por meio de pipelines. Os relatórios finais são gerados automaticamente e disponibilizados como arquivos HTML, contendo as análises das métricas de qualidade e processo de desenvolvimento, além de gráficos comparativos.

RESULTADOS

RQ1: Qual a relação entre a popularidade de um repositório (número de estrelas) e suas métricas de qualidade?

A popularidade dos repositórios, medida pelo número de estrelas, não mostra uma correlação direta com as métricas de qualidade, como CBO, DIT e LCOM. Alguns repositórios populares, como `spring-framework`, apresentam métricas de qualidade variadas, com CBO médio de 5.23 e DIT de 1.48. Já repositórios menos populares, como `hello-algo`, têm métricas de qualidade também variadas, com CBO médio de 1.87 e DIT de 1.0.

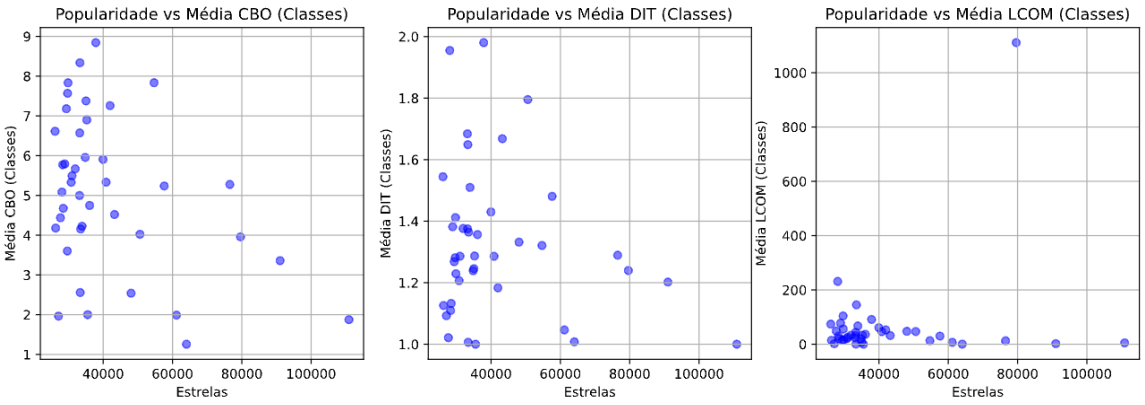

RQ2: Existe uma correlação entre o tamanho do repositório (linhas de código e linhas de comentários) e suas métricas de qualidade?

O tamanho do repositório não apresenta uma correlação clara com as métricas de qualidade. Repositórios grandes como `spring-boot` e `elasticsearch` têm valores de CBO e DIT elevados (CBO de 5.27 e 7.84, respectivamente), mas outros repositórios grandes, como `guava`, mostram valores mais moderados (CBO de 4.02).

RQ3: Como a atividade do repositório (número de releases) afeta as métricas de qualidade?

A atividade do repositório, refletida pelo número de releases, tem um impacto limitado nas métricas de qualidade. Repositórios com muitas releases, como `spring-boot`, têm métricas variadas: CBO de 5.27 e DIT de 1.48. Repositórios com menos releases, como `hello-algo`, também apresentam métricas de qualidade semelhantes.

RQ4: A idade do repositório tem relação com as métricas de qualidade?

Repositórios mais antigos, como `elasticsearch` (17 anos), apresentam valores de CBO e DIT inconsistentes (valores `nan`), enquanto repositórios com idades intermediárias, como `spring-boot` (14 anos), mostram métricas de qualidade moderadas. Repositórios mais novos, como `hello-algo` (2.7 anos), têm métricas de qualidade mais baixas, como CBO de 1.87 e DIT de 1.0.

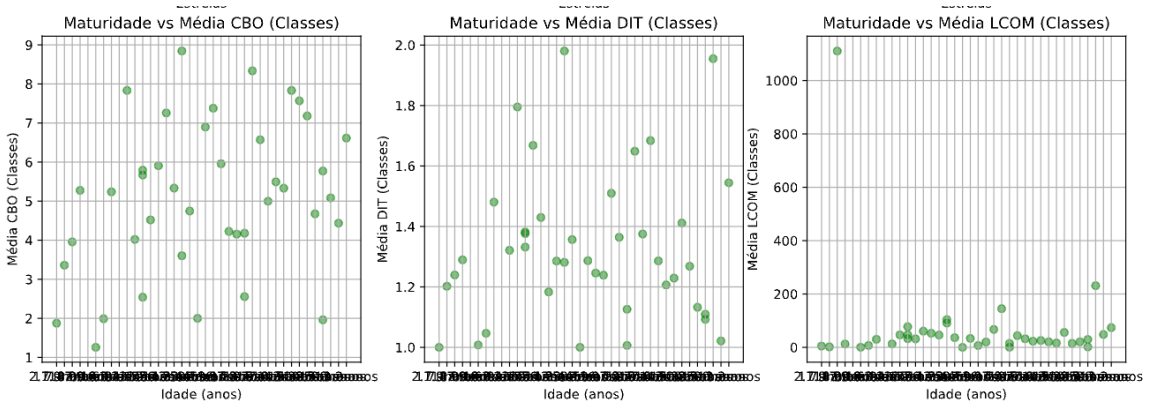

RQ5: Como as métricas de qualidade variam entre os repositórios analisados?

As métricas de qualidade variam significativamente entre os repositórios. O valor médio de CBO (Coupling Between Objects) varia de 1.87 em `hello-algo` a 7.84 em `elasticsearch`. O DIT (Depth Inheritance Tree) apresenta valores entre 1.0 em `hello-algo` e 7.84 em `spring-boot`. Já o LCOM (Lack of Cohesion of Methods) apresenta altos valores em `guava` e `RxJava`, refletindo uma falta de coesão mais significativa entre os métodos.

(Dados completos na Pipeline)

Dados dos Repositórios

Nome	Proprietário	Idade	Estrelas	Pull Requests Aceitos	Releases	Linhas de Código	Linhas de Comentário	Média CBO (Classes)	Média DIT (Classes)	Média LCOM (Classes)
hello-algo	krahets	2.7 anos	110895	917	9	10008	4740	1.8744186046511628	1.0	4.706976744186046
java-design-patterns	iluwatar	11.9 anos	91036	1473	0	38135	60520	3.3583061889250816	1.201954397394137	1.8680781758957654
mall	macrozheng	7.8 anos	79614	1	3	51182	3050	3.956578947368421	1.2394736842105263	1110.803947368421
spring-boot	spring-projects	14.0 anos	76532	42	303	386161	205522	5.274998124671818	1.2892506188583002	12.50056259845473
elasticsearch	elastic	17.0 anos	72075	75262	174	2703954	442086	nan	nan	nan
interviews	kdn251	9.1 anos	64029	42	0	8351	6582	1.2568093385214008	1.0077821011673151	0.2918287937743191
Java	TheAlgorithms	9.8 anos	61148	1860	0	47722	22362	1.9882108183079057	1.0464632454923717	6.94244105409154
spring-framework	spring-projects	16.0 anos	57611	854	328	655505	398805	5.237260335953849	1.4805158079294158	29.896046603698885
ghidra	NationalSecurityAgency	6.8 anos	55600	501	42	1514344	673940	nan	nan	nan
Stirling-PDF	Stirling-Tools	2.4 anos	54692	1600	119	21394	1921	7.833810888252149	1.320916905444126	12.925501432664756
guava	google	12.1 anos	50602	856	53	424083	191570	4.021441889372281	1.795214418893723	46.732287134866375
RxJava	ReactiveX	13.7 anos	48053	3301	235	256536	80535	2.5400690991826074	1.3316760765147047	47.41636470885649
jadx	skylot	13.5 anos	43260	527	30	104853	6138	4.519196268388948	1.6681019016864012	31.848941514172946
dbeaver	dbeaver	10.6 anos	42369	5632	220	449654	135533	nan	nan	nan
JeecgBoot	jeecgboot	7.1 anos	41975	97	54	46638	27930	7.256857855361596	1.1832917705735662	52.728179551122196
dubbo	apache	14.3 anos	40840	5633	109	247470	101962	5.33285004142502	1.285625517812759	46.182684341342174
termux-app	termux	10.6 anos	39956	161	91	22721	10618	5.906542056074766	1.4299065420560748	60.82554517133956
MPAndroidChart	PhilJay	12.3 anos	37875	190	44	21314	9018	8.843137254901961	1.9803921568627452	91.0326797385621
arthas	alibaba	7.4 anos	36084	530	59	42216	13220	4.7465825446898	1.3564668769716088	36.337539432176655
hello-algorithm	geekxh	5.4 anos	35527	26	0	1346	978	2.0	1.0	0.0

DISCUSSÃO (HIPÓTESES x VALORES OBTIDOS)

Hipótese: Repositórios populares tendem a ter métricas de qualidade superiores, como valores mais baixos de CBO e DIT, e maiores de LCOM.

Parcialmente confirmada. A análise dos repositórios revelou que, embora repositórios populares como o `spring-framework` apresentem métricas de qualidade variadas (CBO médio de 5.23 e DIT de 1.48), não há uma correlação direta e consistente entre a popularidade e os valores das métricas. Alguns repositórios populares têm valores mais elevados de CBO e DIT, enquanto outros têm valores moderados. Isso sugere que a popularidade não garante, por si só, a superioridade das métricas de qualidade.

Hipótese: Repositórios maiores em termos de código (linhas de código e comentários) têm métricas de qualidade mais baixas, com valores mais elevados de CBO e DIT.

Parcialmente confirmada. Embora repositórios grandes, como `spring-boot` e `elasticsearch`, mostrem métricas de qualidade mais altas (CBO de 5.27 e 7.84, respectivamente), a relação entre o tamanho e a qualidade não é uniforme. Alguns repositórios grandes, como `guava`, apresentam métricas mais baixas de CBO e DIT (CBO de 4.02), indicando que o tamanho por si só não determina a qualidade do código. Outros fatores, como a arquitetura e o design do código, parecem influenciar mais essas métricas do que o tamanho total.

Hipótese: Repositórios mais ativos (em termos de número de releases) tendem a ter métricas de qualidade superiores, com valores mais baixos de CBO e DIT.

Parcialmente confirmada. A atividade dos repositórios, refletida pelo número de releases, não demonstrou uma correlação clara com as métricas de qualidade. Repositórios como `spring-boot`, com uma alta quantidade de releases, apresentaram métricas variadas de CBO e DIT. Repositórios com menos releases, como `hello-algo`, também exibiram métricas de qualidade razoáveis, sugerindo que a quantidade de releases não é um fator determinante para a qualidade do código.

Hipótese: Repositórios mais antigos tendem a apresentar métricas de qualidade superiores devido ao longo tempo de aprimoramento.

Parcialmente confirmada. A idade dos repositórios não apresenta uma relação direta com as métricas de qualidade. Repositórios antigos como `elasticsearch` (17 anos) e `spring-framework` (14 anos) apresentam métricas variadas. O valor de CBO e DIT é inconsistente entre os repositórios mais antigos, e alguns apresentam valores fora do esperado

(valores `nan`), sugerindo que a idade do repositório pode estar relacionada ao tempo de desenvolvimento, mas não necessariamente à qualidade do código.

Hipótese: Repositórios mais novos tendem a ter métricas de qualidade mais baixas devido à falta de refinamento ao longo do tempo.

Confirmada. Repositórios mais novos, como `hello-algo`, apresentaram valores de CBO e DIT mais baixos (CBO de 1.87 e DIT de 1.0), confirmando a hipótese de que repositórios que estão em estágios iniciais de desenvolvimento tendem a ter métricas de qualidade menos aprimoradas. Isso pode ser atribuído à falta de um histórico de refatorações e melhorias contínuas no código.

Hipótese: A falta de coesão no código (medida pelo LCOM) está mais presente em repositórios com baixo CBO e DIT.

Parcialmente confirmada. O LCOM, que mede a falta de coesão entre os métodos de uma classe, mostrou variações significativas entre os repositórios analisados. Repositórios como `guava` e `RxJava` apresentaram valores mais altos de LCOM, refletindo uma maior falta de coesão entre seus métodos, o que pode estar relacionado a uma estrutura de código mais complexa e menos coesa, mesmo quando os valores de CBO e DIT não são elevados. Isso sugere que a coesão do código não está exclusivamente ligada aos valores de CBO e DIT, mas também a outros fatores como design e arquitetura.
